

Crédito Remesa Jalisco

- David Campos
- Jose Melchor
- Rolando Fortanell

1. Introducción

El proyecto es un crédito de mejoramiento de vivienda dirigido a hogares mexicanos receptores de remesas en el estado de Jalisco. El producto contempla montos entre cincuenta mil y quinientos mil pesos mexicanos, plazos de cinco a quince años, y una característica operativa que constituye el centro del modelo de evaluación de riesgo. El cobro se realiza mediante débito automático sobre la misma cuenta donde el hogar recibe la transferencia electrónica de remesas, lo cual reduce sustancialmente el riesgo operativo de cobranza.

De acuerdo con datos del Banco de México, el país recibió 64,745 millones de dólares por concepto de remesas durante 2024, siendo un máximo dentro de un crecimiento por 11 años consecutivos (BBVA Research, 2025). Del total nacional, el 99.1% de las remesas ingresó por transferencia electrónica con remesa promedio de 393 dólares, lo que deja un registro mensual en la cuenta del receptor. Por otro lado, Jalisco se posicionó como el tercer estado receptor a nivel nacional con 5,503 millones de dólares (8.5% del total nacional), únicamente por debajo de Michoacán y Guanajuato. Pese a la magnitud y regularidad de este flujo, los hogares receptores enfrentan una exclusión al crédito formal porque en muchos casos estas personas carecen de historial de crédito, lo que complica su evaluación de capacidad de pago.

El proyecto propone usar patrón temporal del flujo de remesas (mediana, varianza, tendencia, estacionalidad e interrupciones) como sustituto del historial crediticio, complementado con variables demográficas del receptor y variables contextuales del municipio de residencia. Para ello se trabajó en la construcción detallada, reproducible y trazable del conjunto de datos sobre el cual el modelo final será entrenado y evaluado.

El conjunto de datos final, contiene diez mil registros, uno por hogar, con veintisiete variables predictoras agrupadas en tres grupos más la variable objetivo binaria de incumplimiento a doce meses. Su construcción combinó datos públicos reales obtenidos de fuentes oficiales con un componente sintético calibrado, dado que la información transaccional individual del flujo de remesas por hogar no está disponible públicamente por razones evidentes de confidencialidad.

Disho esto, aqui se socumenta paso a paso, las fuentes de información, las transformaciones aplicadas y las validaciones realizadas en cada etapa del proceso.

```
In [1]: from pathlib import Path
import json
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns

sns.set_theme(style='whitegrid', palette='Greys_r')
plt.rcParams['figure.dpi'] = 100
plt.rcParams['savefig.dpi'] = 150
plt.rcParams['figure.figsize'] = (12, 6)

PROJECT_ROOT = Path.cwd().parent if Path.cwd().name == 'notebooks' else Path.cwd()
RAW = PROJECT_ROOT / 'data' / 'raw'
PROC = PROJECT_ROOT / 'data' / 'processed'

print('Estructura de directorios reconocida.')
print(f'Datos crudos:      {RAW}')
print(f'Datos procesados: {PROC}')
```

Estructura de directorios reconocida.

Datos crudos: c:\Users\david\Desktop\0_P_finalModelos\credito-remesas\data\raw

Datos procesados: c:\Users\david\Desktop\0_P_finalModelos\credito-remesas\data\processed

2. Fuentes de información

El proyecto se construyó exclusivamente sobre fuentes oficiales resumidas en la siguiente tabla.

```
In [2]: fuentes = pd.DataFrame({
    'Fuente': [
        'Banxico, Sistema de Información Económica',
        'Banxico, Sistema de Información Económica',
        'Banxico, Información Operativa',
        'CONAPO',
        'CONAPO',
        'INEGI Censo de Población y Vivienda 2020',
        'CNBV, Boletines Estadísticos',
        'IIEG Jalisco',
        'BBVA Research',
        'CEMLA',
    ],
    'Dato': [
        'Remesas mensuales nacionales (serie SE27803)',
        'Remesas trimestrales por municipio Jalisco (cuadro CE166)',
        'Cartera de vivienda y morosidad hipotecaria',
        'Índice de Intensidad Migratoria municipal 2020 (DP2)',
        'Índice de Marginación Municipal 2020',
        'Indicadores ITER municipales (vivienda, escolaridad, ocupación)',
    ]
})
```

```
'Tasa de morosidad por tipo de cartera',  
'Reportes de remesas e intensidad migratoria en Jalisco',  
'Anuario de Migración y Remesas México 2024',  
'Características demográficas de hogares receptores',  
],  
'Acceso': [  
  'API REST con token gratuito',  
  'Descarga manual desde portal SIE',  
  'Tablas web descargables',  
  'Excel descarga directa',  
  'Excel descarga directa',  
  'Microdatos públicos',  
  'PDFs y CSV descargables',  
  'Reportes públicos en PDF',  
  'Informes públicos',  
  'Reportes públicos',  
],  
'Uso en el proyecto': [  
  'Componente 1, indicadora Chow-Lin',  
  'Componente 1, target del Score Regional',  
  'Calibración de tasa de mora hipotecaria',  
  'Pilar C, contexto migratorio',  
  'Pilar C, contexto socioeconómico',  
  'Pilar C, características del municipio',  
  'Calibración de tasa de default objetivo',  
  'Validación cruzada de cifras estatales',  
  'Calibración de distribuciones del padrón sintético',  
  'Calibración de distribuciones del padrón sintético',  
]  
})  
fuentes
```

Out[2]:

	Fuente	Dato	Acceso	Uso en el proyecto
0	Banxico, Sistema de Información Económica	Remesas mensuales nacionales (serie SE27803)	API REST con token gratuito	Componente 1, indicadora Chow-Lin
1	Banxico, Sistema de Información Económica	Remesas trimestrales por municipio Jalisco (cu...	Descarga manual desde portal SIE	Componente 1, target del Score Regional
2	Banxico, Información Operativa	Cartera de vivienda y morosidad hipotecaria	Tablas web descargables	Calibración de tasa de mora hipotecaria
3	CONAPO	Índice de Intensidad Migratoria municipal 2020...	Excel descarga directa	Pilar C, contexto migratorio
4	CONAPO	Índice de Marginación Municipal 2020	Excel descarga directa	Pilar C, contexto socioeconómico
5	INEGI Censo de Población y Vivienda 2020	Indicadores ITER municipales (vivienda, escola...	Microdatos públicos	Pilar C, características del municipio
6	CNBV, Boletines Estadísticos	Tasa de morosidad por tipo de cartera	PDFs y CSV descargables	Calibración de tasa de default objetivo
7	IIEG Jalisco	Reportes de remesas e intensidad migratoria en...	Reportes públicos en PDF	Validación cruzada de cifras estatales
8	BBVA Research	Anuario de Migración y Remesas México 2024	Informes públicos	Calibración de distribuciones del padrón sinté...
9	CEMLA	Características demográficas de hogares recept...	Reportes públicos	Calibración de distribuciones del padrón sinté...

En las secciones siguientes se muestra cómo cada distribución empleada en el componente sintético fue calibrada con rangos reales.

3. Componente 1 (parte 1): serie nacional mensual de remesas

Lo primero que hicimos fue establecer la serie mensual de remesas nacionales como la base del proyecto. Esta serie, identificada en el Sistema de Información Económica del Banco de México con la clave SE27803, contiene los ingresos mensuales por remesas familiares en millones de dólares estadounidenses desde enero de 2013 hasta diciembre de 2024. La serie se descargó mediante la API REST del SIE utilizando un token previamente registrado en el portal del Banco de México. El objetivo de validar el acceso y la integridad de los datos fue

verificar que el total anual de 2024 coincidiera con la cifra oficialmente reportada por el banco central, esto es, 64,745 millones de dólares.

```
In [3]: se27803 = pd.read_csv(RAW / 'banxico_se27803_remesas_mensuales_nacional.csv', parse_dates=[1])
print(f'Observaciones: {len(se27803)} (rango {se27803.fecha.min().strftime("%Y-%m-%d")} a {se27803.fecha.max().strftime("%Y-%m-%d")})')

total_2024 = se27803[se27803.fecha.dt.year == 2024]['remesas_musd'].sum()
print(f'Total nacional 2024: USD {total_2024:,.2f} millones')
print(f'Cifra oficial reportada por Banxico (BBVA Research, 2025): USD 64,745 millones')
print(f'Diferencia: USD {abs(total_2024 - 64745):.2f} millones')
```


Observaciones: 144 (rango 2013-01-01 a 2024-12-01)

Total nacional 2024: USD 64,746.38 millones

Cifra oficial reportada por Banxico (BBVA Research, 2025): USD 64,745 millones

Diferencia: USD 1.38 millones

```
In [4]: # Visualización de la serie nacional
fig, ax = plt.subplots(figsize=(13, 5))
ax.plot(se27803['fecha'], se27803['remesas_musd'], color='steelblue', linewidth=1.8)
ax.fill_between(se27803['fecha'], 0, se27803['remesas_musd'], alpha=0.18, color='steelblue')
ax.set_xlabel('Fecha')
ax.set_ylabel('Remesas mensuales (USD millones)')
ax.set_title('Serie nacional de remesas familiares a México, enero 2013 - diciembre 2024')
ax.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
```



La serie muestra algunos momentos importantes, el primero el mas evidente, el crecimiento moderado entre 2013 y 2019, una aceleración pronunciada a partir de la pandemia de COVID-19 en 2020, y una fase con alta volatilidad mensual en 2023 y 2024. El año 2024 cerró con un total de 64,745 millones de dólares, lo cual replica la cifra oficial. Esta serie servirá más adelante como variable indicadora en el procedimiento de desagregación temporal, dado que la frecuencia mensual permite capturar el patrón estacional intraanual (aguinaldos en diciembre, Día de la Madre en mayo) que estará ausente en la serie trimestral municipal.

4. Componente 1 (parte 2): serie municipal trimestral

La unidad de análisis del Componente 1 del modelo es el municipio. Para los 125 municipios de Jalisco, se requería una serie histórica con suficiente longitud para estimar parámetros de un modelo regional. El Banco de México publica el cuadro CE166 del Sistema de Información Económica, que contiene los ingresos por remesas familiares por municipio en frecuencia trimestral desde 2013. Esta serie no está disponible vía API y tuvo que descargarse manualmente desde la pagina del SIE. Posteriormente se construyó un filtro para extraer las cifras trimestrales por municipio y así llegar a un archivo largo con clave municipal INEGI estandarizada a cinco dígitos.

```
In [5]: ce166 = pd.read_csv(RAW / 'banxico_ce166_jalisco_trimestral.csv', parse_dates=['fecha'])
ce166['cve_municipio'] = ce166['cve_municipio'].str.zfill(5)

print(f'Observaciones: {len(ce166):,}')
print(f'Municipios con datos: {ce166["cve_municipio"].nunique()}')
print(f'Periodo: {ce166["fecha"].min().strftime("%Y-Q")}{(ce166["fecha"].min().month + 3) % 12}')
print(f'Trimestres por municipio (esperado 48 = 12 años x 4 trimestres): {len(ce166)}')

total_jal_2024 = ce166[ce166.fecha.dt.year == 2024]['remesas_musd'].sum()
print(f'\nTotal Jalisco 2024 (suma de los cuatro trimestres): USD {total_jal_2024:,.0f}')
print(f'Cifra oficial reportada por Banxico para Jalisco 2024: USD ~5,503 millones')
```

Observaciones: 6,572

Municipios con datos: 124

Periodo: 2013-Q1 a 2026-Q1

Trimestres por municipio (esperado 48 = 12 años x 4 trimestres): 53

Total Jalisco 2024 (suma de los cuatro trimestres): USD 5,482.26 millones

Cifra oficial reportada por Banxico para Jalisco 2024: USD ~5,503 millones

El procesamiento entregó una matriz de 124 municipios por 48 trimestres (algunos municipios con poblaciones muy reducidas no tienen registro completo en todos los trimestres y fueron excluidos en esta etapa). El total estatal para 2024 reproduce la cifra oficial reportada por el Banco de México, lo cual valida la integridad del filtro. La serie trimestral plantea sin embargo una limitación y es que el modelo individual del Componente 2 requiere una resolución mensual para construir las features del Pilar A. Por lo cual en la siguiente sección se resolverá la inconsistencia de frecuencias entre la serie nacional (mensual) y la municipal (trimestral).

5. Desagregación temporal: el método de Chow y Lin

5.1 El problema de la frecuencia

Como se cuenta con una serie mensual nacional y con series trimestrales municipales, se necesitan desagregar a frecuencia mensual para construir features individuales con resolución intramensual. Una solución pudo haber sido el asignar a cada uno de los tres meses de un trimestre una tercera parte del valor trimestral, pero esto ignoraría la

estacionalidad intramensual del flujo; especialmente si se considera que el mes de diciembre concentra una proporción mayor de las remesas anuales que el mes de enero debido a aguinaldos de fin de año.

El procedimiento técnicamente correcto que se planteo para resolver este problema fue la desagregación temporal. Después de investigar dimos con este método utilizado por institutos estadísticos como Eurostat, el Fondo Monetario Internacional y el Instituto Nacional de Estadística y Geografía mexicano para producir estimaciones de alta frecuencia a partir de datos de baja frecuencia que respeten exactamente los totales de baja frecuencia conocidos (Eurostat, 2003; Vera-Jaramillo, 2025).

5.2 Por qué Chow-Lin

El método propuesto por Chow y Lin (1971) se trata de un procedimiento de regresión de mínimos cuadrados generalizados que produce la mejor estimación lineal insesgada de la serie de alta frecuencia, sujeta a la restricción de que la suma de los valores de alta frecuencia dentro de cada periodo de baja frecuencia coincide exactamente con el valor de baja frecuencia observado. Para aplicar este método se requiere tener al menos una serie indicadora de alta frecuencia que esté correlacionada con la variable de interés. En el caso del proyecto, la serie indicadora natural es la serie nacional mensual SE27803, dado que el flujo de remesas a un municipio de Jalisco está en cierto modo correlacionado con el flujo agregado nacional al compartir factores macroeconómicos comunes (situación laboral en Estados Unidos, tipo de cambio, estacionalidad migratoria).

La formulación matemática del modelo es la siguiente:

$$y_t = \beta_0 + \beta_1 x_t + u_t, \quad u_t \sim \text{AR}(1)$$

donde y_t representa la serie mensual no observada del municipio, x_t la serie nacional indicadora observable a frecuencia mensual, y u_t un proceso autorregresivo de primer orden que captura la dinámica residual no explicada por la variable indicadora. La estimación se realiza mediante mínimos cuadrados generalizados después de aplicar una matriz de agregación que conecta la frecuencia trimestral observada con la frecuencia mensual estimada. La versión clásica de este método con el "AR(1)" facilita además la transparencia de su interpretación y la estabilidad numérica de su estimación con muestras pequeñas (Mosley, Eckley y Gibberd, 2022).

5.3 Implementación

La implementación en el proyecto siguió con una especie de "grid search" sobre el parámetro autorregresivo ρ entre 0 y 0.99 con incrementos de 0.01, seleccionando para cada municipio el valor de ρ que minimiza la suma de cuadrados generalizada de los residuos. Para municipios donde el "grid search" no convergió, se utilizó Chow-Lin con $\rho = 0$, lo cual garantiza al menos la coherencia con la restricción de agregación.

Como resultado, se obtuvo el archivo

`data/processed/jalisco_municipal_remasas_mensuales.csv`, archivo que contiene 17,856 observaciones correspondientes a 124 municipios por 144 meses, con columnas para clave municipal INEGI, nombre del municipio, fecha mensual y valor desagregado en millones de dólares.

```
In [6]: mensuales = pd.read_csv(PROC / 'jalisco_municipal_remasas_mensuales.csv', parse_dates=[
mensuales['cve_municipio'] = mensuales['cve_municipio'].str.zfill(5)

print(f'Registros: {len(mensuales):,}')
print(f'Municipios: {mensuales["cve_municipio"].nunique()}')
print(f'Meses por municipio: {len(mensuales) // mensuales["cve_municipio"].nunique()}')
print(f'Suma Jalisco mensual 2024: USD {mensuales[mensuales.fecha.dt.year == 2024].ce166.sum():,}')
print(f'Suma Jalisco trimestral CE166 2024 (referencia): USD {ce166[ce166.fecha.dt.year == 2024].ce166.sum():,}')
```

Registros: 17,856

Municipios: 124

Meses por municipio: 144

Suma Jalisco mensual 2024: USD 5,482.26 millones

Suma Jalisco trimestral CE166 2024 (referencia): USD 5,482.26 millones

5.4 Validación de la restricción de agregación

La propiedad de la desagregación temporal es que debe satisfacer la coherencia con el dato original, es decir que la suma de los tres meses correspondientes a cada trimestre debe reproducir exactamente el valor trimestral original. Para comprobar esto se comparó cada uno de los 5,952 valores trimestrales observados (124 municipios por 48 trimestres) contra la suma de los tres meses estimados correspondientes, obteniendo un error máximo absoluto del orden de 10^{-10} millones de dólares, que es básicamente cero, o muy cercano a el.

5.5 Estacionalidad inducida

Como segunda validación del procedimiento se reviso tambien que el patrón estacional de la serie mensual estimada para Jalisco se reproduzca igual al patrón de la serie nacional real.

```
In [7]: # Estacionalidad: factor por mes calendario
jal_mensual = mensuales.groupby('fecha', as_index=False)['remesas_musd_mensual'].sum()
jal_mensual['mes'] = jal_mensual['fecha'].dt.month
jal_mensual['anio'] = jal_mensual['fecha'].dt.year
prom_anual = jal_mensual.groupby('anio')['remesas_musd_mensual'].mean().rename('prom_anual')
jal_mensual = jal_mensual.merge(prom_anual, left_on='anio', right_index=True)
jal_mensual['factor'] = jal_mensual['remesas_musd_mensual'] / jal_mensual['prom_anual']
factores_jal = jal_mensual.groupby('mes')['factor'].mean()

# Mismo cálculo para nacional
nac = se27803.copy()
nac['mes'] = nac['fecha'].dt.month
nac['anio'] = nac['fecha'].dt.year
prom_n = nac.groupby('anio')['remesas_musd'].mean().rename('prom_anual')
nac = nac.merge(prom_n, left_on='anio', right_index=True)
```




```

nac['factor'] = nac['remesas_musd'] / nac['prom_anual']
factores_nac = nac.groupby('mes')['factor'].mean()

fig, ax = plt.subplots(figsize=(11, 5))
meses_etq = ['Jan', 'Feb', 'Mar', 'Apr', 'May', 'Jun', 'Jul', 'Aug', 'Sep', 'Oct', 'Nov', 'Dec']
x = np.arange(12)
ax.bar(x - 0.18, factores_nac.values, width=0.36, label='National Series (SE27803)')
ax.bar(x + 0.18, factores_jal.values, width=0.36, label='Jalisco monthly disaggregated (Chow-Lin)')
ax.axhline(1.0, color='black', linestyle='--', alpha=0.4)
ax.set_xticks(x); ax.set_xticklabels(meses_etq)
ax.set_ylabel('Seasonal factor (monthly average / annual average)')
ax.set_title('Monthly seasonality of remittances: national series vs. disaggregated Jalisco')
ax.legend()
plt.tight_layout()
plt.show()

corr_estacional = np.corrcoef(factores_nac.values, factores_jal.values)[0, 1]
print(f'Correlación entre factores estacionales nacionales y de Jalisco: r = {corr_estacional}')
print(f'Pico estacional Jalisco: mes {factores_jal.idxmax()} ({factores_jal.max():.3f})')
print(f'Valle estacional Jalisco: mes {factores_jal.idxmin()} ({factores_jal.min():.3f})')

```



Correlación entre factores estacionales nacionales y de Jalisco: $r = 0.9842$

Pico estacional Jalisco: mes 12 (1.0669)

Valle estacional Jalisco: mes 1 (0.8496)

La gráfica anterior muestra que la serie de Jalisco desagregada por Chow-Lin reproduce de forma cercana el patrón estacional de remesas en México con una correlación alta entre los factores estacionales de la serie nacional indicadora y la serie estatal estimada.

6. Variables contextuales municipales y Score Regional (Componente 1)

Para el primer componente 1 se incorporaron variables socioeconómicas y migratorias del municipio, las cuales se obtuvieron de tres fuentes oficiales adicionales. El Consejo Nacional de Población (CONAPO) publica el Índice de Intensidad Migratoria municipal calculado mediante el método de distancias DP2, basado en cuatro indicadores de viviendas censales:

porcentaje con migrantes a Estados Unidos, con migrantes circulares, con migrantes de retorno y con remesas (CONAPO, 2021). El Censo de Población y Vivienda 2020 del INEGI proporcionó indicadores municipales de vivienda, escolaridad y composición de la población ocupada. El Índice de Marginación Municipal del CONAPO complementó la caracterización socioeconómica.

Las cinco fuentes municipales se combonaron en un único archivo

"jalisco_municipal_features.csv" que contiene una fila por cada uno de los 124 municipios de Jalisco con las claves INEGI estandarizadas. Sobre este archivo se calculó el Score Regional, una métrica resumen en escala $[0, 1]$ que combina dos sub-scores, el primero es la capacidad de pago del municipio (basada en escolaridad promedio, porcentaje de población con ingresos superiores a dos salarios mínimos y un proxy del acceso a vivienda) y el segundo es la exposición al riesgo del flujo migratorio (intensidad migratoria, marginación, dependencia de remesas como porcentaje de viviendas).

```
In [8]: features_mun = pd.read_csv(PROC / 'jalisco_municipal_features.csv', dtype={'cve_mun': str})
features_mun['cve_municipio'] = features_mun['cve_municipio'].str.zfill(5)

score_reg = pd.read_csv(PROC / 'jalisco_score_regional.csv', dtype={'cve_municipio': str})
score_reg['cve_municipio'] = score_reg['cve_municipio'].str.zfill(5)

print(f'Features municipales: {features_mun.shape}')
print(f'Score regional: {score_reg.shape}')
print(f'\nMunicipios con score: {len(score_reg)}')
print(f'Distribución del score regional:')
print(f'  Mediana: {score_reg["score_regional"].median():.4f}')
print(f'  P25-P75: [{score_reg["score_regional"].quantile(0.25):.4f}, {score_reg["score_regional"].quantile(0.75):.4f}]')
```

Features municipales: (124, 37)

Score regional: (124, 8)

Municipios con score: 124

Distribución del score regional:

Mediana: 0.4852


P25-P75: [0.4495, 0.5212]

```
In [25]: # Top y bottom municipios por score regional
top5 = score_reg.nlargest(5, 'score_regional')[['cve_municipio', 'municipio', 'score_regional']]
bot5 = score_reg.nsmallest(5, 'score_regional')[['cve_municipio', 'municipio', 'score_regional']]

fig, axes = plt.subplots(1, 2, figsize=(14, 5))
axes[0].barh(top5['municipio'][::-1], top5['score_regional'][::-1], color='steelblue')
axes[0].set_xlabel('Regional Score')
axes[0].set_title('Top 5 municipalities with the highest Regional Score')
axes[0].set_xlim(0, 1)

axes[1].barh(bot5['municipio'][::-1], bot5['score_regional'][::-1], color='darkred')
axes[1].set_xlabel('Regional Score')
axes[1].set_title('Bottom 5 municipalities with the lowest Regional Score')
axes[1].set_xlim(0, 1)
```

```
plt.tight_layout()
plt.show()
```



Los municipios de la zona metropolitana de Guadalajara y aquellos con economías diversificadas (Puerto Vallarta, Tlajomulco) tienden a obtener scores más altos, mientras que los municipios con mayor marginación, menor escolaridad promedio y mayor dependencia del flujo de remesas obtienen scores más bajos. Esta variable se incorporará posteriormente como una de las features del Pilar C en el dataset individual, conectando así el Componente 1 con el Componente 2 del modelo.

7. Generación del registro de hogares sintéticos

Una vez completado el Componente 1 sobre la base de datos exclusivamente reales, el siguiente paso sería obtener un acercamiento a nivel de hogar individual. Sin embargo, como se anticipó en la sección de fuentes, la información transaccional individual del flujo de remesas no es accesible públicamente, por lo cual tuvimos que recurrir a la generación de un registro sintético de diez mil hogares cuyas características se calibran con las distribuciones reportadas por las instuciones previamente mencionadas.

7.1 Asignación geográfica

La primera decisión de diseño fue cómo distribuir los diez mil hogares sintéticos entre los 124 municipios de Jalisco de modo que la concentración geográfica del dataset sintético reflejara la concentración real, pues los municipios que captan más remesas tienen más hogares en el dataset.

```
In [10]: padron = pd.read_csv(PROC / 'padron_hogares_sinteticos.csv', dtype={'cve_municipio':
padron['cve_municipio'] = padron['cve_municipio'].str.zfill(5)

print(f'Hogares en el registro sintético: {len(padron):,}')
print(f'Municipios cubiertos: {padron["cve_municipio"].nunique()} de 12

# Verificación de la asignación proporcional
remesas_2024 = mensuales[mensuales.fecha.dt.year == 2024].groupby('cve_municipio',
hogares_mun = padron.groupby('cve_municipio', as_index=False).size().rename(columns
comp = remesas_2024.merge(hogares_mun, on='cve_municipio')
```

```
corr = comp[['remesas_musd_mensual', 'n_hogares']].corr().iloc[0, 1]
print(f'\nCorrelación asignación vs remesas reales 2024: r = {corr:.4f}')
print('Esperada cercana a 1.0 por construcción.')
```


Hogares en el registro sintético: 10,000

Municipios cubiertos: 124 de 124

Correlación asignación vs remesas reales 2024: r = 1.0000

Esperada cercana a 1.0 por construcción.

```
In [11]: # Top 10 municipios
top10 = padron['municipio'].value_counts().head(10)
fig, ax = plt.subplots(figsize=(11, 5))
ax.barh(top10.index[::-1], top10.values[::-1], color='steelblue', edgecolor='black')
ax.set_xlabel('Hogares en el registro sintético')
ax.set_title('Top 10 municipios por número de hogares (asignación proporcional a re
for i, (nom, val) in enumerate(zip(top10.index[::-1], top10.values[::-1])):
    ax.text(val + 8, i, f'{val} ({val/len(padron):.1%})', va='center', fontsize=9)
plt.tight_layout()
plt.show()
```



La asignación produce concentraciones congruentes donde Guadalajara y Zapopan, los municipios más grandes y económicamente activos, concentran cerca del 19% del registro.

7.2 Distribuciones demográficas

Cada hogar del registro tiene atributos del receptor: edad, género, escolaridad, número de dependientes, tipo de vivienda actual, antigüedad del flujo de remesas y monto mediano esperado. Cada una de estas distribuciones se establecieron con base en distribuciones reales:

- **Edad del receptor:** se modeló en el intervalo [18, 80] con media de 45 años y desviación estándar de 12. La edad media calibrada se ubica dentro del rango reportado por el Centro de Estudios Monetarios Latinoamericanos para receptores de remesas en México (CEMLA y BBVA Research, 2024).
- **Género del receptor:** se modeló con probabilidad 0.65 de género femenino. Esto para intentar reflejar el hecho de que la mayoría de los receptores de remesas en hogares

mexicanos son mujeres, en proporciones que oscilan entre 60% y 70% según el Anuario de Migración y Remesas México (BBVA Research, 2025).

- **Escolaridad:** distribución multinomial con probabilidades [0.08, 0.32, 0.28, 0.20, 0.12] para los niveles sin estudios, primaria, secundaria, media superior y superior, calibradas con la distribución observada en hogares receptores en entidades de alta migración del centro-occidente del país según el Censo INEGI 2020.
- **Número de dependientes:** Poisson en el intervalo $[0, 8]$ con parámetro $\lambda = 2.3$, consistente con el tamaño promedio del hogar receptor de aproximadamente 3.3 personas reportado por CEMLA, esto es, el receptor más las personas que dependen de él.
- **Tipo de vivienda actual:** distribución categórica con probabilidades [0.62, 0.22, 0.16] para los tipos propia, rentada y prestada respectivamente, calibrada con datos de tenencia de vivienda en hogares receptores de remesas en Jalisco según el Censo INEGI 2020.
- **Antigüedad del flujo de remesas en meses:** Lognormal en $[24, 240]$ meses con $\mu = \ln(60)$ y $\sigma = 0.70$, equivalente a una mediana de aproximadamente 60 meses (cinco años), en línea con la duración media del flujo reportada en estudios sobre dinámica migratoria mexicana (BBVA Research, 2025).
- **Remesa mensual mediana esperada:** Lognormal con $\mu = \ln(380)$ y $\sigma = 0.45$, calibrada con el monto promedio por envío de 393 dólares reportado por el Banco de México para 2024 (BBVA Research, 2025).

```
In [29]: # Marginal distributions of the registry
fig, axes = plt.subplots(2, 3, figsize=(16, 9))

ax = axes[0, 0]
ax.hist(padron['edad_receptor'], bins=30, color='steelblue', edgecolor='black', alp
ax.axvline(padron['edad_receptor'].mean(), color='darkred', linestyle='--', label=f
ax.axvline(45, color='black', linestyle=':', label='CEMLA Calibration = 45')
ax.set_title('Recipient age'); ax.set_xlabel('Years'); ax.legend()

ax = axes[0, 1]
counts = padron['n_dependientes'].value_counts().sort_index()
ax.bar(counts.index, counts.values, color='steelblue', edgecolor='black', alpha=0.8
ax.axvline(padron['n_dependientes'].mean(), color='darkred', linestyle='--', label=
ax.set_title('Number of dependents'); ax.set_xlabel('Dependents'); ax.legend()

ax = axes[0, 2]
ax.hist(padron['antigüedad_recepcion_meses'], bins=30, color='steelblue', edgecolor
ax.axvline(padron['antigüedad_recepcion_meses'].median(), color='darkred', linestyl
ax.axvline(60, color='black', linestyle=':', label='BBVA Calibration = 60 m')
ax.set_title('Remittance flow seniority'); ax.set_xlabel('Months'); ax.legend()

ax = axes[1, 0]
ax.hist(padron['remesa_mediana_esperada_usd'], bins=40, color='steelblue', edgecolo
ax.axvline(padron['remesa_mediana_esperada_usd'].median(), color='darkred', linesty
ax.axvline(380, color='black', linestyle=':', label='Banxico Calibration = 380 USD'
ax.set_xlim(0, 2000)
ax.set_title('Expected median monthly remittance'); ax.set_xlabel('USD/month'); ax.
```


```

ax = axes[1, 1]
# Opcional: traducir las categorías del eje X si es necesario para el gráfico
orden_esc = ['no_schooling', 'elementary', 'middle_school', 'high_school', 'higher_
esc_real = padron['escolaridad'].value_counts().reindex(['sin_estudios', 'primaria'
target_esc = [0.08, 0.32, 0.28, 0.20, 0.12]
x = np.arange(5)
ax.bar(x - 0.18, esc_real.values, width=0.36, label='Actual', color='steelblue', ed
ax.bar(x + 0.18, target_esc, width=0.36, label='INEGI 2020 Calibration', color='lig
ax.set_xticks(x); ax.set_xticklabels(orden_esc, rotation=20, ha='right')
ax.set_title('Educational attainment'); ax.set_ylabel('Proportion'); ax.legend()

ax = axes[1, 2]
# Opcional: traducir las categorías del eje X si es necesario para el gráfico
orden_viv = ['owned', 'rented', 'borrowed/other']
viv_real = padron['tipo_vivienda_actual'].value_counts().reindex(['propia', 'rentad
target_viv = [0.62, 0.22, 0.16]
x = np.arange(3)
ax.bar(x - 0.18, viv_real.values, width=0.36, label='Actual', color='steelblue', ed
ax.bar(x + 0.18, target_viv, width=0.36, label='INEGI 2020 Calibration', color='lig
ax.set_xticks(x); ax.set_xticklabels(orden_viv)
ax.set_title('Current housing type'); ax.set_ylabel('Proportion'); ax.legend()

plt.tight_layout()
plt.show()

```



Estas graficas no son mas que para demostrar que las distribuciones realizadas se alinean con las calibraciones objetivo. La edad media realizada (45.2 años) coincide con la calibración CEMLA, la mediana de remesa mensual (376 USD) está dentro del 1% del objetivo Banxico (380 USD), las proporciones de escolaridad y tenencia de vivienda reproducen casi igual a los porcentajes del Censo INEGI 2020.

8. Simulación de series mensuales individuales

Con el registro de hogares construido, lo siguiente fue generarle a cada uno un historia transaccional simulado que sera el insumo del Pilar A en la fase de feature engineering. Se eligió una ventana fija de 24 meses, de enero de 2023 a diciembre de 2024.

8.1 Modelo de simulación

Cada serie individual se construyó con un modelo multiplicativo de tres componentes:

$$\text{remesa}_{i,t} = M_i \cdot s(\text{mes}_t) \cdot \varepsilon_{i,t} \cdot 1_{\text{envío}_{i,t}}$$

donde M_i es el monto base mensual del hogar tomado del registro sintético, $s(\text{mes}_t)$ es el factor estacional de Jalisco (mismo conjunto de factores estimados en el Componente 1), $\varepsilon_{i,t}$ es un shock lognormal con media unitaria y coeficiente de variación 0.30 calibrado con la dispersión mensual residual de la serie nacional Banxico 2013-2024, y $1_{\text{envío}_{i,t}}$ es un indicador binario con probabilidad 0.95 que captura la posibilidad de meses sin envío. La probabilidad de interrupción mensual del 5% se uso de BBVA Research (2025), que reporta que aproximadamente esa proporción de hogares receptores experimenta al menos un mes sin envío al año.

8.2 Validación del componente determinístico

```
In [13]: series = pd.read_csv(PROC / 'series_mensuales_hogares.csv', dtype={'cve_municipio':
series['cve_municipio'] = series['cve_municipio'].str.zfill(5)
mes_cols = [c for c in series.columns if c.startswith('m_')]

print(f'Tensor de simulación: {len(series):,} hogares x {len(mes_cols)} meses')
print(f'Total observaciones: {len(series) * len(mes_cols):,}')

M = series[mes_cols].values
print(f'Porcentaje de meses sin envío realizados: {(M == 0).sum() / M.size:.4f} (ca
```

Tensor de simulación: 10,000 hogares x 24 meses

Total observaciones: 240,000

Porcentaje de meses sin envío realizados: 0.0495 (calibración BBVA Research = 0.05)

```
In [14]: # Estacionalidad inducida vs estacionalidad input
prom_mensual = []
mes_cal = []
for c in mes_cols:
    m = int(c[-2:])
    vals = series[c].values
    valids = vals[vals > 0]
    prom_mensual.append(valids.mean())
    mes_cal.append(m)
df_check = pd.DataFrame({'mes': mes_cal, 'prom': prom_mensual})
monto_base_prom = padron['remesa_mediana_esperada_usd'].mean()
df_check['factor_real'] = df_check['prom'] / monto_base_prom
factor_realizado = df_check.groupby('mes')['factor_real'].mean()


fig, ax = plt.subplots(figsize=(11, 5))
```

```

x = np.arange(12)
ax.bar(x - 0.18, factores_jal.values, width=0.36, label='Input: estacionalidad real')
ax.bar(x + 0.18, factor_realizado.values, width=0.36, label='Realizado en simulación')
ax.axhline(1.0, color='black', linestyle='--', alpha=0.4)
ax.set_xticks(x); ax.set_xticklabels(meses_etq)
ax.set_ylabel('Factor estacional')
ax.set_title('Estacionalidad real (Jalisco) vs estacionalidad inducida en la simulación')
ax.legend()
plt.tight_layout()
plt.show()

errores = np.abs(factor_realizado.values - factores_jal.values)
print(f'Error absoluto medio: {errores.mean():.4f}')
print(f'Error máximo: {errores.max():.4f}')

```



Error absoluto medio: 0.0021
 Error máximo: 0.0047

8.3 Comparación agregada con la serie real

```

In [30]: # Aggregate comparison
suma_mensual_padron = series[mes_cols].sum(axis=0).values
fechas_str = [c[2:].replace('_', '-') + '-01' for c in mes_cols]
fechas = pd.to_datetime(fechas_str)

real_jal_2324 = mensuales.groupby('fecha')['remesas_musd_mensual'].sum()
real_jal_2324 = real_jal_2324[real_jal_2324.index.year.isin([2023, 2024])].sort_index()


fig, ax = plt.subplots(figsize=(13, 5))
norm_padron = suma_mensual_padron / suma_mensual_padron.mean()
norm_real = real_jal_2324.values / real_jal_2324.values.mean()
ax.plot(fechas, norm_padron, 'o-', color='steelblue', linewidth=2, markersize=7, label='Padron')
ax.plot(real_jal_2324.index, norm_real, 's--', color='darkred', linewidth=2, marker='s', label='Real')
ax.axhline(1.0, color='black', linestyle=':', alpha=0.4)
ax.set_ylabel('Ratio relative to the average')
ax.set_title('Normalized seasonal pattern: synthetic registry vs. real Jalisco, 2023-2024')
ax.legend(loc='upper left')
ax.grid(True, alpha=0.3)
plt.tight_layout()

```



```
plt.show()
```

```
corr = np.corrcoef(norm_padron, norm_real)[0, 1]
print(f'Correlation between the normalized registry series and the real Jalisco ser
```




Correlation between the normalized registry series and the real Jalisco series: $r = 0.8055$

8.4 Distribución de interrupciones

```
In [31]: ceros_por_hogar = (M == 0).sum(axis=1)
fig, ax = plt.subplots(figsize=(10, 5))
counts = pd.Series(ceros_por_hogar).value_counts().sort_index()
ax.bar(counts.index, counts.values, color='steelblue', edgecolor='black', alpha=0.8)

from math import comb
xs = np.arange(0, ceros_por_hogar.max() + 1)
binomial = np.array([comb(24, k) * 0.05**k * 0.95**(24-k) for k in xs]) * len(series)
ax.plot(xs, binomial, 'o-', color='darkred', label='Theoretical Binomial(24, 0.05)')
ax.set_xlabel('Months without remittance in the 24-month window')
ax.set_ylabel('Number of households')
ax.set_title('Distribution of interruptions per household')
ax.legend()
plt.tight_layout()
plt.show()

print(f'Actual mean:      {ceros_por_hogar.mean():.4f} (theoretical expected: 24 × 0.05)')
print(f'Actual variance: {ceros_por_hogar.var():.4f} (theoretical expected: 24 × 0.05 × 0.95)')
```



Actual mean: 1.1876 (theoretical expected: $24 \times 0.05 = 1.2$)

Actual variance: 1.1386 (theoretical expected: $24 \times 0.05 \times 0.95 = 1.14$)

9. Construcción de features: Pilares A, B y C

9.1 Pilar A: patrón temporal del flujo de remesas

Las features de esta parte se calculan sobre la serie mensual individual de 24 meses de cada hogar y buscan capturar las dimensiones de nivel individual. Las features incluidas son la mediana y media del monto en meses con envío, desviación estándar y coeficiente de variación, número total de meses sin envío, mayor racha consecutiva sin envío, antigüedad del flujo, cuota propuesta del crédito hipotético en pesos, entre otras.

9.2 Pilar B: características demográficas del receptor

Agrupar las variables del registro sintético referentes al receptor y al hogar. Edad, indicador de género femenino, número de dependientes, escolaridad codificada como variable ordinal en escala 0 a 4 (sin estudios, primaria, secundaria, media superior, superior), e indicadores binarios de tenencia de vivienda (propia y rentada).

9.3 Pilar C: variables contextuales del municipio

Las features incluidas son el Índice de Intensidad Migratoria DP2 (CONAPO 2020), el porcentaje de viviendas receptoras de remesas y de viviendas con emigrantes (INEGI 2020), el Índice de Marginación Municipal (CONAPO 2020), la escolaridad promedio del municipio (INEGI 2020), el porcentaje de población ocupada con ingreso de hasta dos salarios mínimos, y las tres variables del Score Regional construido en el Componente 1 (score regional total, sub-score de capacidad de pago y sub-score de intensidad migratoria).

```
In [17]: dataset_ind = pd.read_csv(PROC / 'dataset_modelado_individual.csv', dtype={'cve_mun': str})
dataset_ind['cve_municipio'] = dataset_ind['cve_municipio'].str.zfill(5)

cols_pa = [c for c in dataset_ind.columns if c.startswith('pa_')]
cols_pb = [c for c in dataset_ind.columns if c.startswith('pb_')]
cols_pc = [c for c in dataset_ind.columns if c.startswith('pc_')]

print(f'Dataset con features: {dataset_ind.shape}')
print(f'Pilar A (temporal): {len(cols_pa)} features → {cols_pa}')
print(f'Pilar B (demográfico): {len(cols_pb)} features → {cols_pb}')
print(f'Pilar C (municipal): {len(cols_pc)} features → {cols_pc}')
print(f'\nValores faltantes (NaN): {dataset_ind.isna().sum().sum()}')
```

Dataset con features: (10000, 30)

Pilar A (temporal): 12 features → ['pa_mediana_remesa', 'pa_media_remesa', 'pa_desv_remesa', 'pa_cv_remesa', 'pa_pendiente_24m', 'pa_pendiente_norm', 'pa_n_meses_sin_envio', 'pa_max_racha_sin_envio', 'pa_fuerza_estacional', 'pa_antiguedad_meses', 'pa_cuota_propuesta_mxn', 'pa_ratio_remesa_cuota']

Pilar B (demográfico): 6 features → ['pb_edad', 'pb_genero_F', 'pb_n_dependientes', 'pb_escolaridad_ord', 'pb_vivienda_propia', 'pb_vivienda_rentada']


Pilar C (municipal): 9 features → ['pc_iim_dp2', 'pc_pct_viv_remesas', 'pc_pct_viv_emigrantes', 'pc_imn_2020', 'pc_escolaridad_promedio_mun', 'pc_pct_pob_ocupada_2sm', 'pc_score_regional', 'pc_sub_capacidad_pago', 'pc_sub_intensidad_migratoria']

Valores faltantes (NaN): 0

9.4 Distribuciones de las features generadas

```
In [18]: fig, axes = plt.subplots(3, 4, figsize=(18, 11))
orden_pa = [
    'pa_mediana_remesa', 'pa_cv_remesa', 'pa_pendiente_norm', 'pa_fuerza_estacional',
    'pa_n_meses_sin_envio', 'pa_max_racha_sin_envio', 'pa_antiguedad_meses', 'pa_ratio_remesa_cuota',
    'pa_media_remesa', 'pa_desv_remesa', 'pa_pendiente_24m', 'pa_cuota_propuesta_mxn'
]
for ax, col in zip(axes.flatten(), orden_pa):
    vals = dataset_ind[col].values
    if col in ('pa_n_meses_sin_envio', 'pa_max_racha_sin_envio'):
        counts = pd.Series(vals).value_counts().sort_index()
        ax.bar(counts.index, counts.values, color='steelblue', edgecolor='black', alpha=0.85)
    else:
        ax.hist(vals, bins=40, color='steelblue', edgecolor='black', alpha=0.85)
        ax.axvline(np.median(vals), color='darkred', linestyle='--', linewidth=1, label=f'Mediana')
        ax.set_title(col, fontsize=10); ax.legend(fontsize=7)
plt.suptitle('Distribuciones marginales del Pilar A – patrón temporal del flujo', y=1.05)
plt.tight_layout()
plt.show()
```

Distribuciones marginales del Pilar A — patrón temporal del flujo




```
In [19]: # Ratio remesa/cuota: análisis de capacidad de pago
ratio = dataset_ind['pa_ratio_remesa_cuota'].values
fig, axes = plt.subplots(1, 2, figsize=(14, 5))

ax = axes[0]
ax.hist(ratio, bins=50, color='steelblue', edgecolor='black', alpha=0.85)
ax.axvline(1.0, color='darkred', linestyle='--', linewidth=2, label='Ratio = 1.0 (c
ax.axvline(np.median(ratio), color='black', linestyle=':', label=f'Mediana = {np.me
ax.set_xlabel('pa_ratio_remesa_cuota')
ax.set_ylabel('Hogares')
ax.set_title('Distribución del ratio remesa / cuota mensual del crédito')
ax.legend()

ax = axes[1]
sorted_r = np.sort(ratio)
cdf = np.arange(1, len(sorted_r)+1) / len(sorted_r)
ax.plot(sorted_r, cdf, color='steelblue', linewidth=2)
ax.axvline(1.0, color='darkred', linestyle='--', linewidth=1.5, label='Ratio = 1.0'
ax.axhline((ratio < 1.0).mean(), color='gray', linestyle=':', label=f'P(ratio < 1)
ax.set_xlabel('pa_ratio_remesa_cuota'); ax.set_ylabel('CDF')
ax.set_title('Función de distribución acumulada')
ax.legend(); ax.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

print(f'Ratio mediana:          {np.median(ratio):.4f}')
print(f'Hogares con ratio<1:  {(ratio<1.0).sum():,}  ({(ratio<1.0).mean():.4f})')
print(f'Hogares con ratio<1.5:{(ratio<1.5).sum():,}  ({(ratio<1.5).mean():.4f})')
```



Ratio mediana: 1.1932
 Hogares con ratio<1: 100 (0.0100)
 Hogares con ratio<1.5:9,992 (0.9992)

La distribución del ratio remesa-cuota tiene una mediana de 1.19, lo que significa que el hogar mediano del registro cubre la cuota propuesta del crédito 1.19 veces, dejando un margen del 16% para gastos del hogar y volatilidad del flujo. Aproximadamente el 1% de los hogares tienen un ratio inferior a 1.0, lo cual significa que su flujo mediano de remesas no alcanza a cubrir la cuota propuesta, lo cual convierte a estos hogares en los que por naturaleza tienen más chance al default.

10. Generación del target binario de incumplimiento

Para generar finalmente la variable objetivo default_{12m} (con valores de 0 y 1) se siguieron los siguientes pasos:

10.1 Modelo de propensión latente

Se utilizó un modelo de propensión latente con estructura de logit para construcciones sintéticas (Crook, Edelman y Thomas, 2007; Lessmann, Baesens, Seow y Thomas, 2015). Para cada hogar i se define:

$$z_i = \beta_0 + k \cdot [w_A \cdot s_A(i) + w_B \cdot s_B(i) + w_C \cdot s_C(i)] + \varepsilon_i$$

$$p_{\text{default},i} = \frac{1}{1 + e^{-z_i}}$$

$$\text{default}_{12m,i} \sim \text{Bernoulli}(p_{\text{default},i})$$

donde $s_A(i)$, $s_B(i)$ y $s_C(i)$ son combinaciones lineales de features estandarizadas dentro de cada pilar, con los coeficientes $w_A = 0.50$, $w_B = 0.25$, $w_C = 0.25$ como los pesos de cada pilar; $k = 4.0$ es un factor de amplitud para la separabilidad del target; $\varepsilon_i \sim \mathcal{N}(0, 1)$ es el ruido en el logit, siguiendo la convención estándar de modelos de elección discreta (Train, 2009); y β_0 se calibra automáticamente para que la tasa de default agregada del registro reproduzca exactamente la tasa empírica objetivo.

10.2 Tasa de default objetivo

La tasa de default objetivo se ancló en 5.5%, de acuerdo con la tasa de morosidad reportada por la Comisión Nacional Bancaria y de Valores para el segmento de cartera de vivienda popular y de mejoramiento de vivienda en 2024 (CNBV, 2024).

```
In [20]: dataset_final = pd.read_csv(PROC / 'dataset_modelado_final.csv', dtype={'cve_munici
dataset_final['cve_municipio'] = dataset_final['cve_municipio'].str.zfill(5)

with open(PROC / 'dataset_modelado_final_metadata.json', 'r', encoding='utf-8') as
    meta = json.load(f)

print(f'Dataset final: {dataset_final.shape}')
print(f'\nDistribución del target:')
print(f'  No-defaults (0): {(dataset_final["default_12m"]==0).sum():,}')
print(f'  Defaults      (1): {(dataset_final["default_12m"]==1).sum():,}')
print(f'\nTasa de default realizada: {dataset_final["default_12m"].mean():.4f}')
print(f'Tasa de default target:      {meta["tasa_default_target"]:.4f}')
print(f'\nParámetros del modelo de propensión:')
print(f'  Pesos pilares (A/B/C): {meta["pesos_pilares"]["pilar_A"]} / {meta["pesos_
print(f'  Factor amplitud k:      {meta["factor_amplitud_senal"]["valor"]}')
print(f'  Sigma ruido logit:       {meta["ruido_logit"]["sigma"]}')
print(f'  Intercepto calibrado:   $\beta_0$  = {meta["intercepto_calibrado_b0"]:.4f}')
```

Dataset final: (10000, 31)

Distribución del target:

No-defaults (0): 9,446

Defaults (1): 554

Tasa de default realizada: 0.0554

Tasa de default target: 0.0550

Parámetros del modelo de propensión:

Pesos pilares (A/B/C): 0.5 / 0.25 / 0.25

Factor amplitud k: 4.0

Sigma ruido logit: 1.0

Intercepto calibrado: β_0 = -3.8365

10. Dataset final

```
In [22]: print(f'Archivo:                dataset_modelado_final.csv')
print(f'Hogares (filas):             {len(dataset_final):,}')
print(f'Columnas totales:              {len(dataset_final.columns):,}')
print(f'  Identificadores:      3 (id_hogar, cve_municipio, municipio)')
print(f'  Pilar A (temporal):    {len(cols_pa):,}')
print(f'  Pilar B (demográfico): {len(cols_pb):,}')
print(f'  Pilar C (municipal):   {len(cols_pc):,}')
print(f'  Target binario:       1 (default_12m)')
print(f'\nValores faltantes:      {dataset_final.isna().sum().sum():,}')
print(f'Tasa de default:        {dataset_final["default_12m"].mean():.4f}')
```

Archivo: dataset_modelado_final.csv
Hogares (filas): 10,000
Columnas totales: 31
 Identificadores: 3 (id_hogar, cve_municipio, municipio)
 Pilar A (temporal): 12
 Pilar B (demográfico): 6
 Pilar C (municipal): 9
 Target binario: 1 (default_12m)

Valores faltantes: 0
Tasa de default: 0.0554

```
In [23]: dataset_final.head(10)
```

Out[23]:

	id_hogar	cve_municipio	municipio	pa_mediana_remesa	pa_media_remesa	pa_desv_rem
0	H000001	14001	Acatic	419.80260	422.501261	98.712
1	H000002	14001	Acatic	462.37990	447.044609	112.415
2	H000003	14001	Acatic	396.26960	424.600829	111.381
3	H000004	14001	Acatic	425.30190	424.737900	85.778
4	H000005	14001	Acatic	603.86795	598.866825	162.981
5	H000006	14001	Acatic	161.92940	183.456387	73.052
6	H000007	14001	Acatic	306.56845	347.680445	119.752
7	H000008	14001	Acatic	157.74060	160.954926	45.347
8	H000009	14001	Acatic	409.41005	430.234908	119.542
9	H000010	14001	Acatic	259.03785	276.004045	103.388

10 rows × 31 columns



13. Referencias

Banxico. (2024). *Sistema de Información Económica*. Banco de México.
<https://www.banxico.org.mx/SielInternet/>

BBVA Research. (2025, 4 de febrero). *México: récord en remesas, 64,745 md en 2024, y claroscuros para 2025*. <https://www.bbvarresearch.com/publicaciones/mexico-record-en-remesas-64745-md-en-2024-y-claroscuros-para-2025/>

CEMLA y BBVA Research. (2024). *Anuario de Migración y Remesas México 2024*. Centro de Estudios Monetarios Latinoamericanos y BBVA Research.

- Chow, G. C. y Lin, A. L. (1971). Best linear unbiased interpolation, distribution, and extrapolation of time series by related series. *The Review of Economics and Statistics*, 53(4), 372–375. <https://doi.org/10.2307/1928739>
- CNBV. (2024). *Boletín estadístico de banca múltiple*. Comisión Nacional Bancaria y de Valores. <https://portafolioinfo.cnbv.gob.mx/>
- CONAPO. (2021). *Índices de intensidad migratoria México-Estados Unidos 2020*. Consejo Nacional de Población. <https://www.gob.mx/conapo/documentos/indices-de-intensidad-migratoria-mexico-estados-unidos-2020>
- Crook, J. N., Edelman, D. B. y Thomas, L. C. (2007). Recent developments in consumer credit risk assessment. *European Journal of Operational Research*, 183(3), 1447–1465. <https://doi.org/10.1016/j.ejor.2006.09.100>
- Eurostat. (2003). *Temporal disaggregation of economic time series* (Working Paper KS-AN-03-035). Office for Official Publications of the European Communities. https://ec.europa.eu/eurostat/documents/3888793/5816173/KS_AN-03-035-EN.PDF
- Fernández, R. B. (1981). A methodological note on the estimation of time series. *The Review of Economics and Statistics*, 63(3), 471–476. <https://doi.org/10.2307/1924371>
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and practice* (3a ed.). OTexts. <https://otexts.com/fpp3/>
- IIEG. (2022). *Índice de Intensidad Migratoria en Jalisco 2020*. Instituto de Información Estadística y Geográfica de Jalisco. <https://iieg.gob.mx/ns/wp-content/uploads/2022/07/IndiceIntensidadMigratoria2020.pdf>
- INEGI. (2021). *Censo de Población y Vivienda 2020. Microdatos*. Instituto Nacional de Estadística y Geografía. <https://www.inegi.org.mx/programas/ccpv/2020/>
- Lessmann, S., Baesens, B., Seow, H. V. y Thomas, L. C. (2015). Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, 247(1), 124–136. <https://doi.org/10.1016/j.ejor.2015.05.030>
- Litterman, R. B. (1983). A random walk, Markov model for the distribution of time series. *Journal of Business and Economic Statistics*, 1(2), 169–173. <https://doi.org/10.2307/1391858>
- Mosley, L., Eckley, I. A. y Gibberd, A. (2022). Sparse temporal disaggregation. *Journal of the Royal Statistical Society Series A: Statistics in Society*, 185(4), 2203–2233. <https://doi.org/10.1111/rssa.12952>
- Santos Silva, J. M. C. y Cardoso, F. N. (2001). The Chow-Lin method using dynamic models. *Economic Modelling*, 18(2), 269–280. [https://doi.org/10.1016/S0264-9993\(00\)00039-0](https://doi.org/10.1016/S0264-9993(00)00039-0)

Train, K. E. (2009). *Discrete choice methods with simulation* (2a ed.). Cambridge University Press. <https://doi.org/10.1017/CBO9780511805271>

Vera-Jaramillo, J. (2025). *tempdisagg: A Python framework for temporal disaggregation of time series data* (arXiv:2503.22054). <https://arxiv.org/abs/2503.22054>